

งานวิจัยที่เกี่ยวข้อง

รายงานว่าผู้ป่วยที่มีข้อจำกัดด้านภาษาอังกฤษ (LEP) มีความเสี่ยงสูงขึ้นอย่างมีนัยสำคัญต่อความผิดพลาดทางการแพทย์ โดยเฉพาะเมื่อไม่มีบริการล่ามที่เหมาะสม พบว่าการมีบริการล่ามทางโทรศัพท์ในโรงพยาบาลสามารถลดอัตราการกลับเข้ารับการรักษาซ้ำใน

30 วันของผู้ป่วย LEP จากร้อยละ 17.8 เหลือร้อยละ 13.4 ซึ่งคิดเป็นค่าใช้จ่ายที่ประหยัดได้ถึง 161,404 ดอลลาร์สหรัฐต่อเดือน ขณะที่พบว่าผู้ป่วย LEP ที่อยู่ในไอซียูมีค่าใช้จ่ายสูงกว่าผู้ป่วยที่พูดภาษาอังกฤษได้อย่างมีนัยสำคัญ ในทำนองเดียวกัน ชี้ให้เห็นว่าระบบ SCADA และระบบควบคุมอุตสาหกรรมอื่น ๆ มีความเสี่ยงสูงเมื่อเชื่อมต่อกับเครือข่ายภายนอก ซึ่งซอฟต์แวร์ควบคุมจำนวนมากพัฒนาขึ้นโดยผู้ผลิตต่างชาติ ทำให้ส่วนติดต่อผู้ใช้แสดงผลเป็นภาษาต่างประเทศที่ผู้ปฏิบัติงานในท้องถิ่นอาจไม่เข้าใจ ระบุว่าการจัดการทางทะเลระหว่างประเทศ

(IMO) กำหนดให้เรือ
สินค้าและเรือโดยสาร
ระหว่างประเทศ
ต้องติดตั้งระบบ

ECDIS ซึ่งมาตรฐาน
ดังกล่าวได้รับการ
ปรับปรุงหลายครั้ง

แต่ซอฟต์แวร์นำทาง
เหล่านี้ยังคงแสดง
ผลเป็นภาษาอังกฤษ
เป็นหลัก ด้านการ
บรรเทาสาธารณภัย

นำเสนอโครงการ

Words of Relief
โดย Translators
Without Borders
ซึ่งพัฒนาบริการ
แปลภาษาในภาวะ
ฉุกเฉิน แต่ยังคงพึ่งพา
โครงข่ายอินเทอร์เน็ต
และการเชื่อมต่อผ่าน
ดาวเทียมเป็นหลัก

ส่วน ชี้ให้เห็นว่า
อุปสรรคทางภาษาส่ง
ผลกระทบอย่างมีนัย
สำคัญต่อการอนุรักษ์
ความหลากหลาย
ทางชีวภาพ ทั้งใน
ด้านการผลิตองค์
ความรู้โดยนักวิจัยที่
ไม่ได้ใช้ภาษาอังกฤษ
เป็นภาษาหลัก การ
สังเคราะห์องค์ความ
รู้ข้ามภาษา และการ
ประยุกต์ใช้องค์ความ
รู้ในระดับท้องถิ่น

ปัญหาอุปสรรคทาง
ภาษาจึงเป็นปัญหาที่
เกิดขึ้นในวงกว้างและ
ส่งผลร้ายแรงในหลาย
ภาคส่วน นอกเหนือ
จากผลกระทบที่เกิด
ขึ้นแล้ว เครื่องมือ
ที่มีอยู่ในปัจจุบันยัง
ไม่สามารถแก้ปัญหา

นี้ได้ กล่าวถึงข้อ
จำกัดของเทคโนโลยี
การแปลภาษาใน
สถานการณ์วิกฤตที่
โครงข่ายโทรคมนาคม
อาจล่มสลาย ขณะที่
ที่บริการคลาวด์ต้อง
เชื่อมต่ออินเทอร์เน็ต
ตลอดเวลาและส่ง
ข้อมูลไปยังเครื่อง
แม่ข่ายภายนอก ซึ่ง
ใช้การไม่ได้ในพื้นที่ไร้
สัญญาณและละเมิด
กำหนดการรักษา
ความลับของข้อมูล
ส่วนซอฟต์แวร์โอเพน
ซอร์สแบบออฟไลน์ที่
มีอยู่เดิม เช่น Tesser-
act ก็มีข้อจำกัดใน
การรู้จำภาษาไทย

เนื่องจาก Tesseract
ได้รับการออกแบบมา
สำหรับภาษาที่ใช้ชุด
ตัวอักษรละตินเป็น
หลักดังที่ ได้อธิบาย
ไว้ แม้ทีมงานวิจัยที่
พยายามปรับปรุง
ประสิทธิภาพของ

Tesseract สำหรับ
ภาษาไทยโดยเฉพาะ

หรือเปรียบเทียบกับบริการคลาวด์
อย่าง Google
Cloud Vision แต่
ก็ยังคงมีข้อจำกัดด้าน
ความแม่นยำ ดังที่

เปรียบเทียบให้เห็น
ว่า EasyOCR มีค่า

Character Error
Rate (CER) สูง
ถึง 0.298 และ

Tesseract มีค่า CER
สูงถึง 1.061 สำหรับ
เอกสารสองภาษาที่
พิมพ์ดี ข้อจำกัดเหล่านี้

นี้สะท้อนให้เห็นถึง
ความจำเป็นในการ
สำรวจเทคโนโลยี

OCR ที่มี
ประสิทธิภาพสูงขึ้น

สำหรับภาษาที่มีใช้

ภาษาอังกฤษ นำเสนอ

TrOCR ซึ่งเป็นโมเดล

OCR แบบ end-

to-end ตัวแรกที่ใช้

Vision Transformer

เป็นตัวเข้ารหัส ร่วม

กับ Transformer

Decoder ไม่ต้อง

อาศัยขั้นตอนการแบ่ง

ส่วนตัวอักษร และ

สามารถ fine-tune

สำหรับภาษาเฉพาะ

ได้ นำ TrOCR มา

ต่อพ่วงกับ Electra

Decoder และ fine-

tune ด้วยข้อมูล

ภาษาไทย-อังกฤษ

ส่งผลให้มีค่า CER ต่ำ

เพียง 0.053 สำหรับ

เอกสารสองภาษา

อีกแนวทางคือระบบ

OCR แบบ

สองขั้นตอน พัฒนา

PP-OCRv5 ซึ่ง

มีพารามิเตอร์เพียง

5 ล้านค่า

แต่ให้ประสิทธิภาพ

เทียบเท่าโมเดล Vi-

sion-Language

ขนาดใหญ่บนชุด

ข้อมูลมาตรฐาน

ในด้านการสร้าง

ข้อมูลฝึก นำเสนอ

SynthTIGER

ซึ่งเป็นเครื่องมือ

สร้างภาพข้อความ

สังเคราะห์ที่สามารถ

กำหนดฟอนต์

สัญญาณรบกวน

และการกระจายตัว
ของภาษาได้ ทำให้
ได้ข้อมูลฝึกคุณภาพ
สูงโดยไม่ต้องพึ่งพา
ข้อมูลจริงจำนวนมาก

แสดงให้เห็นว่าการ
เพิ่มข้อมูล (data
augmentation)

ด้วยการหมุนภาพ

ปรับความสว่าง และ
เติมสัญญาณรบกวน

Gaussian สามารถ
เพิ่มความแม่นยำของ
โมเดลรู้จำข้อความได้
อย่างมีนัยสำคัญ โดย
ใช้ STRAug ซึ่ง
ประกอบด้วยฟังก์ชัน
36 ฟังก์ชันที่ออกแบบ
มาสำหรับงานรู้จำ
ข้อความบนภาพ

สำรวจเทคนิคการ
เพิ่มข้อมูลภาพอย่าง
เป็นระบบ และยืนยัน
ว่าการแปลงทาง
เรขาคณิต (geomet-
ric transformation)
การปรับช่วงสี

(color space
augmentation)

และการเติม

สัญญาณรบกวนเป็น
วิธีที่มีประสิทธิภาพ

สำหรับงาน

คอมพิวเตอร์วิทัศน์

สำหรับชุดข้อมูล
ประเมิน นำเสนอ

ThaiOCRBench
ซึ่งครอบคลุม 2,808
ภาพจาก 13 ภารกิจ
การรู้จำข้อความ
ภาษาไทย สำรวจ
แนวทางการพัฒนา

OCR สำหรับ
ภาษาทรัพยากรต่ำ

และชี้ว่าการใช้ข้อมูล

สังเคราะห์และการ
เพิ่มข้อมูลเป็นปัจจัย
สำคัญ การวัด CER
ด้วย Levenshtein
distance ระดับตัว
อักษร เป็นมาตรฐาน
ในงาน OCR ที่ใช้
เปรียบเทียบข้ามงาน
วิจัยได้ ความก้าวหน้า
ทาง OCR ดัง
กล่าวจะเกิดประโยชน์
สูงสุดเมื่อสามารถ
เชื่อมต่อกับระบบแปล
ภาษาแบบออฟไลน์
ที่มีคุณภาพ นำเสนอ
NLLB-200 ซึ่งเป็น
โมเดลแบบ Sparsely
Gated Mixture of
Experts ที่รองรับมาก
กว่า 200 ภาษารวม
ถึงไทย โดยมีรุ่นกลั่น
(distilled) ขนาด
600M และ 1.3B
พารามิเตอร์ที่สามารถ
ทำงานบนชิพยู่ทั่วไป
ได้ผ่าน CTranslate2
พัฒนา MetalNLLB
ซึ่งเป็น C Runtime ที่
ใช้หน่วยความจำเพียง
30 MB และมี
throughput สูง
ถึง 10+ tokens/
s บนฮาร์ดแวร์ราคา
ประหยัด แสดง
ให้เห็นว่าการทำ

Knowledge
Distillation ร่วมกับ
INT8 Quantization
สามารถลดขนาด
โมเดลแปลภาษาให้
เหลือเพียง 15 MB
โดยใช้เวลาแปลเพียง
30 มิลลิวินาที
ต่อประโยค นำเสนอ
แนวทางการออกแบบ

สถาปัตยกรรม Transformer ที่คำนึงถึงประสิทธิภาพการใช้พลังงานและการทำงานบนชิพ

สำหรับชุดข้อมูลคู่ภาษา รวบรวม SCB-MT-EN-TH ซึ่งมีมากกว่า 1,000,000 คู่ประโยคภาษาไทย-อังกฤษ ครอบคลุมหลายแหล่งที่มา นำเสนอ FLORES-200 ซึ่งมี 3,001 ประโยคใน 200 ภาษาที่แปลโดยผู้เชี่ยวชาญ

สำหรับการวัดผล เสนอ BLEU Score ซึ่งวัดความแม่นยำของการจับคู่ n -gram $(N=4)$ ร่วมกับ Brevity Penalty และเป็นมาตรฐานหลักในการประเมิน

MT ส่วน กล่าวถึงแนวทางการประเมินคุณภาพการแปลของ WMT ที่ใช้ Direct Assessment (DA) scoring ซึ่งให้ผู้ประเมินที่เป็นเจ้าของภาษาประเมินความถูกต้องเชิง

ความหมาย (Adequacy) บนสเกล 0–100 โดยใช้การทดสอบ Wilcoxon rank-sum สำหรับเปรียบเทียบคู่ระบบ

การปรับใช้โมเดลภาษาขนาดใหญ่เหล่านี้กับงานแปลเฉพาะทางจำเป็นต้องมีเทคนิคการปรับเทียบที่มีประสิทธิภาพ

นำเสนอเทคนิค LoRA (Low-Rank Adaptation) ซึ่งเพิ่มพารามิเตอร์ที่ฝึกได้ $\Delta W = BA$ เข้าไปในชั้น query และ value projection โดยคงน้ำหนักเดิมของแบบจำลองไว้ ทำให้สามารถปรับเทียบโมเดลขนาดใหญ่บนทรัพยากรจำกัดได้

เสนอ Adam optimizer ซึ่งเป็นอัลกอริทึมปรับเทียบที่ปรับอัตราการเรียนรู้ให้เหมาะสมอัตโนมัติ และถูกใช้อย่างแพร่หลายในการปรับเทียบโครงข่ายประสาทเทียม ศึกษาวิธีการหยุดก่อนกำหนด (early stopping) และยืนยันว่าการเฝ้าดูค่า loss บนชุดตรวจสอบและหยุดเมื่อไม่ลดลงเป็นระยะเวลาที่กำหนดเป็นวิธีที่มีประสิทธิภาพในการป้องกัน overfitting กล่าวถึงแนวปฏิบัติมาตรฐานในการแบ่งข้อมูลแบบ hold-out และ stratified split การค้นหาค่าตัวแปรปรับตั้งด้วย

Grid Search และการตั้งค่า seed เพื่อให้ผลลัพธ์ deterministic ตลอดจนการวัดซ้ำหลายรอบ (multiple trials)

เพื่อลดผลกระทบจากความแปรปรวนแบบสุ่ม สำหรับรูปแบบการส่งออกโมเดล

นำเสนอ ONNX Runtime ซึ่งเป็นเอนจินการอนุมานผลที่รองรับหลายแพลตฟอร์ม ในขณะที่

CTranslate2 เป็นเอนจินที่ออกแบบมาเฉพาะสำหรับ

Transformer มี INT8 quantization เพื่อลดขนาดและ

เพิ่มความเร็ว เมื่อโมเดลผ่านการ

ปรับเทียบและแปลง

เป็นรูปแบบที่พร้อม

ใช้งานแล้ว ขั้นตอน

ต่อไปคือการนำไป

ทำงานในโปรแกรม

ประยุกต์ที่ใช้งานได้

จริง เปรียบเทียบ

ประสิทธิภาพระหว่าง

Tauri และ Electron

สำหรับการพัฒนา

โปรแกรมประยุกต์

ข้ามแพลตฟอร์ม พบ

ว่า Tauri มี

ขนาดไบนารีและการ

ใช้หน่วยความจำที่

น้อยกว่าอย่างมีนัย

สำคัญ เนื่องจากใช้

เว็บเทคโนโลยีสำหรับ

ส่วนติดต่อผู้ใช้และ

ภาษาระบบสำหรับ

ส่วนหลังบ้าน พัฒนา

XCap ซึ่งเป็นไลบรารี

จับภาพหน้าจอข้าม

แพลตฟอร์ม รองรับ

Win32/DXGI บน

Windows, Core

Graphics บน

macOS และ XCB/

PipeWire บน Linux โดยใช้ภาษา Rust เป็นภาษาหลักในการพัฒนา ภาษา Rust ซึ่งเป็นภาษาที่ใช้ในการพัฒนาเครื่องมือเหล่านี้ได้รับการยืนยันจาก ว่ามีความปลอดภัยด้านหน่วยความจำ (memory safety) เชิงพื้นที่และเชิงเวลาที่แข็งแกร่งกว่า C ขณะที่ศึกษาข้อบกพร่องในโปรแกรม Rust จึงและยืนยันว่า

Rust สามารถป้องกันปัญหาความปลอดภัยของหน่วยความจำและภาวะพร้อมกัน

(concurrency) ได้อย่างมีประสิทธิภาพผ่านการตรวจสอบในระหว่างการคอมไพล์

การเลือกโครงสร้างพื้นฐานของโปรแกรมประยุกต์ที่เหมาะสมจะส่งผลต่อความน่าเชื่อถือของผลลัพธ์ที่วัดได้ และจำเป็นต้องมีวิธีการทางสถิติที่เหมาะสมในการวิเคราะห์ผลการทดลอง ด้านการวิเคราะห์ผลทางสถิติ

ยืนยันว่า paired t-test ที่ระดับนัยสำคัญ $\alpha = 0.05$ เป็นวิธีที่เหมาะสมสำหรับการเปรียบเทียบประสิทธิภาพของระบบคู่บนชุดข้อมูลเดียวกัน การใช้ repeated measures ช่วยลดความ

แปรปรวนระหว่าง
ตัวอย่างและเพิ่ม
อำนาจการทดสอบ
(statistical power)
เสนอ Cohen's d
สำหรับวัดขนาดผล
(effect size) โดยมีเกณฑ์ $d \geq 0.2$ เล็ก $d \geq 0.5$
กลาง $d \geq 0.8$
ใหญ่ ซึ่งช่วยให้ทราบ
ว่าความแตกต่างที่
มีนัยสำคัญทางสถิติ
นั้นมีความสำคัญใน
ทางปฏิบัติมากน้อย
เพียงใด เสนอการ
ประมาณค่า confidence interval ด้วย
bootstrap ซึ่งเป็นวิธีที่ไม่ต้องสมมติ
การแจกแจงแบบปกติ
ของข้อมูล เหมาะ
สำหรับงานที่ข้อมูล
อาจไม่เป็นไปตามข้อ
ตกลงเบื้องต้นของการ
ทดสอบพารามेटริก

วิธีการทางสถิติเหล่านี้
นี้เป็นพื้นฐานที่สำคัญ
สำหรับการออกแบบ
การทดลองและการ
สรุปผลที่เชื่อถือได้