

งานวิจัยที่เกี่ยวข้อง

รายงานว่าผู้ป่วยที่มีข้อจำกัดด้านภาษาอังกฤษ (LEP) มีความเสี่ยงสูงขึ้นอย่างมีนัยสำคัญต่อความผิดพลาดทางการแพทย์ โดยเฉพาะเมื่อไม่มีบริการล่ามที่เหมาะสม พบว่าการมีบริการล่ามทางโทรศัพท์ในโรงพยาบาลสามารถลดอัตราการกลับเข้ารับการรักษาซ้ำใน

30 วันของผู้ป่วย LEP จากร้อยละ 17.8 เหลือร้อยละ 13.4 ซึ่งคิดเป็นค่าใช้จ่ายที่ประหยัดได้ถึง 161,404 ดอลลาร์สหรัฐต่อเดือน ขณะที่พบว่าผู้ป่วย LEP ที่อยู่ในไอซียูมีค่าใช้จ่ายสูงกว่าผู้ป่วยที่พูดภาษาอังกฤษได้อย่างมีนัยสำคัญ ในทำนองเดียวกัน ชี้ให้เห็นว่าระบบ SCADA และระบบควบคุมอุตสาหกรรมอื่น ๆ มีความเสี่ยงสูงเมื่อเชื่อมต่อกับเครือข่ายภายนอก ซึ่งซอฟต์แวร์ควบคุมจำนวนมากพัฒนาขึ้นโดยผู้ผลิตต่างชาติ ทำให้ส่วนติดต่อผู้ใช้แสดงผลเป็นภาษาต่างประเทศที่ผู้ปฏิบัติงานในท้องถิ่นอาจไม่เข้าใจ ระบุว่าการจัดการทางทะเลระหว่างประเทศ

(IMO) กำหนดให้เรือ
สินค้าและเรือโดยสาร
ระหว่างประเทศ
ต้องติดตั้งระบบ

ECDIS ซึ่งมาตรฐาน
ดังกล่าวได้รับการ
ปรับปรุงหลายครั้ง

แต่ซอฟต์แวร์นำทาง
เหล่านี้ยังคงแสดง
ผลเป็นภาษาอังกฤษ
เป็นหลัก ด้านการ
บรรเทาสาธารณภัย

นำเสนอโครงการ

Words of Relief
โดย Translators
Without Borders
ซึ่งพัฒนาบริการ
แปลภาษาในภาวะ
ฉุกเฉิน แต่ยังคงพึ่งพา
โครงข่ายอินเทอร์เน็ต
และการเชื่อมต่อผ่าน
ดาวเทียมเป็นหลัก

ส่วน ชี้ให้เห็นว่า
อุปสรรคทางภาษาส่ง
ผลกระทบอย่างมีนัย
สำคัญต่อการอนุรักษ์
ความหลากหลาย
ทางชีวภาพ ทั้งใน
ด้านการผลิตองค์
ความรู้โดยนักวิจัยที่
ไม่ได้ใช้ภาษาอังกฤษ
เป็นภาษาหลัก การ
สังเคราะห์องค์ความ
รู้ข้ามภาษา และการ
ประยุกต์ใช้องค์ความ
รู้ในระดับท้องถิ่น

ปัญหาอุปสรรคทาง
ภาษาจึงเป็นปัญหาที่
เกิดขึ้นในวงกว้างและ
ส่งผลร้ายแรงในหลาย
ภาคส่วน นอกเหนือ
จากผลกระทบที่เกิด
ขึ้นแล้ว เครื่องมือ
ที่มีอยู่ในปัจจุบันยัง
ไม่สามารถแก้ปัญหา

นี้ได้ กล่าวถึงข้อ
จำกัดของเทคโนโลยี
การแปลภาษาใน
สถานการณ์วิกฤตที่
โครงข่ายโทรคมนาคม
อาจล่มสลาย ขณะที่
ที่บริการคลาวด์ต้อง
เชื่อมต่ออินเทอร์เน็ต
ตลอดเวลาและส่ง
ข้อมูลไปยังเครื่อง
แม่ข่ายภายนอก ซึ่ง
ใช้การไม่ได้ในพื้นที่ไร้
สัญญาณและละเมิด
กำหนดการรักษา
ความลับของข้อมูล
ส่วนซอฟต์แวร์โอเพน
ซอร์สแบบออฟไลน์
ที่มีอยู่เดิม เช่น
Tesseract ก็มี
ข้อจำกัดในการรู้จำ
ภาษาไทย เนื่องจาก
Tesseract ได้
รับการออกแบบมา
สำหรับภาษาที่ใช้ชุด
ตัวอักษรละตินเป็น
หลักดังที่ ได้อธิบาย
ไว้ แม้ทีมงานวิจัยที่
พยายามปรับปรุง
ประสิทธิภาพของ
Tesseract สำหรับ
ภาษาไทยโดยเฉพาะ
หรือเปรียบเทียบกับ
บริการคลาวด์
อย่าง Google
Cloud Vision แต่
ก็ยังคงมีข้อจำกัดด้าน
ความแม่นยำ ดังที่
เปรียบเทียบให้เห็น
ว่า EasyOCR มีค่า
Character Error
Rate (CER) สูง
ถึง 0.298 และ
Tesseract มีค่า CER
สูงถึง 1.061 สำหรับ
เอกสารสองภาษาที่

พิมพ์ดี ข้อจำกัดเหล่านี้สะท้อนให้เห็นถึงความจำเป็นในการสำรวจเทคโนโลยี

OCR ที่มีประสิทธิภาพสูงขึ้นสำหรับภาษาที่มีใช้

ภาษาอังกฤษ นำเสนอ

TrOCR ซึ่งเป็นโมเดล

OCR แบบ end-to-end ตัวแรกที่ใช้

Vision Transformer เป็นตัวเข้ารหัส ร่วม

กับ Transformer Decoder ไม่ต้อง

อาศัยขั้นตอนการแบ่ง

ส่วนตัวอักษร และสามารถ fine-tune

สำหรับภาษาเฉพาะ

ได้ นำ TrOCR มา

ต่อพ่วงกับ Electra

Decoder และ fine-tune

ด้วยข้อมูลภาษาไทย-อังกฤษ

ส่งผลให้มีค่า CER ต่ำ

เพียง 0.053 สำหรับ

เอกสารสองภาษา

อีกแนวทางคือระบบ

OCR แบบ

สองขั้นตอน พัฒนา

PP-OCRv5 ซึ่ง

มีพารามิเตอร์เพียง

5 ล้านค่า

แต่ให้ประสิทธิภาพ

เทียบเท่าโมเดล

Vision-Language

ขนาดใหญ่บนชุด

ข้อมูลมาตรฐาน

ในด้านการสร้าง

ข้อมูลฝึก นำเสนอ

SynthTIGER

ซึ่งเป็นเครื่องมือ

สร้างภาพข้อความ

สังเคราะห์ที่สามารถ

กำหนดฟอนต์

สัญญาณรบกวน
และการกระจายตัว
ของภาษาได้ ทำให้
ได้ข้อมูลฝึกคุณภาพ
สูงโดยไม่ต้องพึ่งพา
ข้อมูลจริงจำนวนมาก

แสดงให้เห็นว่าการ
เพิ่มข้อมูล (data
augmentation)
ด้วยการหมุนภาพ

ปรับความสว่าง และ
เติมสัญญาณรบกวน

Gaussian สามารถ
เพิ่มความแม่นยำของ
โมเดลรู้จำข้อความได้
อย่างมีนัยสำคัญ โดย
ใช้ STRAug ซึ่ง
ประกอบด้วยฟังก์ชัน

36 ฟังก์ชันที่
ออกแบบมาสำหรับ
งานรู้จำข้อความบน
ภาพ สํารวจเทคนิค
การเพิ่มข้อมูลภาพ
อย่างเป็นระบบ

และยืนยันว่าการ
แปลงทางเรขาคณิต

(geometric
transformation)
การปรับช่วงสี

(color space
augmentation)
และการเติม

สัญญาณรบกวนเป็น
วิธีที่มีประสิทธิภาพ
สำหรับงาน

คอมพิวเตอร์วิทัศน์

สำหรับชุดข้อมูล
ประเมิน นำเสนอ

ThaiOCRBench
ซึ่งครอบคลุม 2,808
ภาพจาก 13 ภารกิจ
การรู้จำข้อความ
ภาษาไทย สํารวจ
แนวทางการพัฒนา

OCR สำหรับ

ภาษาทรัพยากรต่ำ

และชี้ว่าการใช้ข้อมูล
สังเคราะห์และการ
เพิ่มข้อมูลเป็นปัจจัย
สำคัญ การวัด CER
ด้วย Levenshtein
distance ระดับตัว
อักษร เป็นมาตรฐาน
ในงาน OCR ที่ใช้
เปรียบเทียบข้ามงาน
วิจัยได้ ความก้าวหน้า
ทาง OCR ดัง
กล่าวจะเกิดประโยชน์
สูงสุดเมื่อสามารถ

เชื่อมต่อกับระบบแปล
ภาษาแบบออฟไลน์

ที่มีคุณภาพ นำเสนอ

NLLB-200 ซึ่งเป็น
โมเดลแบบ Sparsely
Gated Mixture of
Experts ที่รองรับมาก
กว่า 200 ภาษารวม
ถึงไทย โดยมีรุ่นกลั่น
(distilled) ขนาด

600M และ 1.3B
พารามิเตอร์ที่สามารถ
ทำงานบนชิพยู่ทั่วไป

ได้ผ่าน CTranslate2
พัฒนา MetalNLLB
ซึ่งเป็น C Runtime ที่

ใช้หน่วยความจำเพียง
30 MB และมี

throughput สูง
ถึง 10+ tokens/
s บนฮาร์ดแวร์ราคา
ประหยัด แสดง

ให้เห็นว่าการทำ

Knowledge
Distillation ร่วมกับ

INT8 Quantization
สามารถลดขนาด

โมเดลแปลภาษาให้
เหลือเพียง 15 MB

โดยใช้เวลาแปลเพียง

30 มิลลิวินาที

ต่อประโยค นำเสนอ
แนวทางการออกแบบ
สถาปัตยกรรม

Transformer ที่
คำนึงถึงประสิทธิภาพ
การใช้พลังงานและ
การทำงานบนชิพ

สำหรับชุดข้อมูลคู่
ภาษา รวบรวม SCB-
MT-EN-TH ซึ่งมีมาก
กว่า 1,000,000 คู่
ประโยคภาษาไทย-
อังกฤษ ครอบคลุม
หลายแหล่งที่มา นำ
เสนอ FLORES-200
ซึ่งมี 3,001 ประโยค
ใน 200 ภาษาที่
แปลโดยผู้เชี่ยวชาญ

สำหรับการวัดผล
เสนอ BLEU Score
ซึ่งวัดความแม่นยำ
ของการจับคู่ n -
gram $(N=4)$ รวม
กับ Brevity Penalty
และเป็นมาตรฐาน
หลักในการประเมิน

MT ส่วน กล่าวถึง
แนวทางการประเมิน
คุณภาพการแปลของ

WMT ที่ใช้
Direct Assessment
(DA) scoring ซึ่งให้ผู้
ประเมินที่เป็นเจ้าของ
ภาษาประเมินความ
ถูกต้องเชิงความหมาย

(Adequacy)
บนสเกล 0–100

โดยใช้การทดสอบ
Wilcoxon rank-sum
สำหรับเปรียบเทียบ
คู่ระบบ การปรับ

ใช้โมเดลภาษา
ขนาดใหญ่เหล่านี้
กับงานแปลเฉพาะ
ทางจำเป็นต้องมี

เทคนิคการปรับเทียบ
ที่มีประสิทธิภาพ

นำเสนอเทคนิค

LoRA (Low-Rank Adaptation)
ซึ่งเพิ่มพารามิเตอร์ที่
ฝึกได้ $\Delta W = BA$ เข้าไป
ในชั้น query และ
value projection
โดยคงน้ำหนักเดิม
ของแบบจำลอง
ไว้ ทำให้สามารถ
ปรับเทียบโมเดล
ขนาดใหญ่บน
ทรัพยากรจำกัดได้

เสนอ Adam
optimizer ซึ่งเป็น
อัลกอริทึมปรับเทียบ
ที่ปรับอัตราเรียนรู้ให้
เหมาะสมอัตโนมัติ
และถูกใช้อย่าง
แพร่หลายในการ
ปรับเทียบโครงข่าย
ประสาทเทียม ศึกษา
วิธีการหยุดก่อน
กำหนด (early
stopping) และยืนยัน
ว่าการเฝ้าดูค่า loss
บนชุดตรวจสอบ
และหยุดเมื่อไม่ลด
ลงเป็นระยะเวลาที่
กำหนดเป็นวิธีที่มี
ประสิทธิภาพในการ
ป้องกัน overfitting
กล่าวถึงแนวปฏิบัติ
มาตรฐานในการแบ่ง
ข้อมูลแบบ holdout
และ stratified
split การค้นหาค่า
ตัวแปรปรับตั้งด้วย

Grid Search
และการตรึงค่า

seed เพื่อให้ผลลัพธ์
deterministic

ตลอดจนการวัดซ้ำ
หลายรอบ (multiple
trials) เพื่อลดผล
กระทบจากความ
แปรปรวนแบบสุ่ม

สำหรับรูปแบบ
การส่งออกโมเดล

นำเสนอ ONNX
Runtime ซึ่งเป็น
เอนจินการอนุมาน
ผลที่รองรับหลาย
แพลตฟอร์ม ในขณะที่
CTranslate2 เป็น
เอนจินที่ออกแบบ
มาเฉพาะสำหรับ

Transformer มี
INT8 quantization
เพื่อลดขนาดและ
เพิ่มความเร็ว เมื่อ
โมเดลผ่านการ
ปรับเทียบและแปลง
เป็นรูปแบบที่พร้อม
ใช้งานแล้ว ขั้นตอน
ต่อไปคือการนำไป
ทำงานในโปรแกรม
ประยุกต์ที่ใช้งานได้
จริง เปรียบเทียบ
ประสิทธิภาพระหว่าง

Tauri และ Electron
สำหรับการพัฒนา
โปรแกรมประยุกต์
ข้ามแพลตฟอร์ม พบ
ว่า Tauri มี
ขนาดไบนารีและการ
ใช้หน่วยความจำที่
น้อยกว่าอย่างมีนัย
สำคัญ เนื่องจากใช้
เว็บเทคโนโลยีสำหรับ
ส่วนติดต่อผู้ใช้และ
ภาษาระบบสำหรับ
ส่วนหลังบ้าน พัฒนา
XCap ซึ่งเป็นไลบรารี
จับภาพหน้าจอข้าม
แพลตฟอร์ม รองรับ
Win32/DXGI บน

Windows, Core Graphics บน macOS และ XCB/PipeWire บน Linux โดยใช้ภาษา Rust เป็นภาษาหลักในการพัฒนา ภาษา Rust ซึ่งเป็นภาษาที่ใช้ในการพัฒนาเครื่องมือเหล่านี้ได้รับการยืนยันจาก ว่ามีความปลอดภัยด้านหน่วยความจำ (memory safety) เชิงพื้นที่และเชิงเวลาที่แข็งแกร่งกว่า C ขณะที่ศึกษาข้อบกพร่องในโปรแกรม Rust จริงและยืนยันว่า Rust สามารถป้องกันปัญหาความปลอดภัยของหน่วยความจำและภาวะพร้อมกัน (concurrency) ได้อย่างมีประสิทธิภาพผ่านการตรวจสอบในระหว่างการคอมไพล์

การเลือกโครงสร้างพื้นฐานของโปรแกรมประยุกต์ที่เหมาะสมจะส่งผลต่อความน่าเชื่อถือของผลลัพธ์ที่วัดได้ และจำเป็นต้องมีวิธีการทางสถิติที่เหมาะสมในการวิเคราะห์ผลการทดลอง ด้านการวิเคราะห์ผลทางสถิติ

ยืนยันว่า paired t-test ที่ระดับนัยสำคัญ $\alpha = 0.05$ เป็นวิธีที่เหมาะสมสำหรับการเปรียบเทียบประสิทธิภาพของระบบคู่บนชุด

ข้อมูลเดียวกัน

การใช้ repeated measures ช่วยลดความแปรปรวนระหว่างตัวอย่าง และเพิ่มอำนาจการทดสอบ (statistical power) เสนอ

Cohen's d สำหรับวัดขนาดผล (effect size) โดยมีเกณฑ์ $d \geq 0.2$ เล็ก $d \geq 0.5$ กลาง $d \geq 0.8$ ใหญ่ ซึ่งช่วยให้ทราบว่าความแตกต่างที่มีนัยสำคัญทางสถิตินั้นมีความสำคัญในทางปฏิบัติมากน้อยเพียงใด เสนอการประมาณค่า confidence interval ด้วย

bootstrap ซึ่ง เป็นวิธีที่ไม่ต้องสมมติการแจกแจงแบบปกติของข้อมูล เหมาะสำหรับงานที่ข้อมูลอาจไม่เป็นไปตามข้อตกลงเบื้องต้นของการทดสอบพารามетริก

วิธีการทางสถิติเหล่านี้เป็นพื้นฐานที่สำคัญสำหรับการออกแบบการทดลองและการสรุปผลที่เชื่อถือได้